

Rozkłady dyskretne

Joanna Czarnowska¹

¹Uniwersytet Gdański
Instytut Informatyki
jczarn@inf.ug.edu.pl

Modelowanie wielkości o charakterze losowym

Do opisu wielkości losowych wykorzystujemy zmienne losowe. Badane wielkości mogą być:

- ▶ przeliczalne – liczba wypadków, liczba wypłat z portfela polis, liczba awarii na taśmie, itd.
- ▶ nieprzeliczalne – czas świecenia żarówki, temperatura, prędkość wiatru, poziom cukru we krwi, ciśnienie, ceny akcji na giełdzie, itd.

Pierwsze wielkości opisują **zmienne losowe dyskretne**, drugie – **zmienne losowe ciągłe**. Zmienne losowe oznacza się zwykle dużymi literami X , Y czy Z (w przeszłości częściej literami ξ , η , ζ).

Precyzyjna definicja zmiennej losowej – 01RozkladyDyskretne.pdf

Rozkład zmiennej losowej dyskretnej

Podając wartości jakie przyjmuje zmienna losowa dyskretna

$$X \in \{x_1, x_2, x_3, \dots\}$$

oraz prawdopodobieństwa ich wystąpienia

$$p_1 = P(X=x_1), \quad p_2 = P(X=x_2), \quad p_3 = P(X=x_3), \dots$$

określamy **rozkład prawdopodobieństwa** (krótko **rozkład**) tej zmiennej. Przy czym zachodzi

$$p_1 + p_2 + p_3 + \dots = 1, \quad p_i \geq 0.$$

Zmienna losowa dyskretna – przykład

Przykład

Rzucamy raz kostką symetryczną. W zależności od wypadniętej liczby oczek wygrywamy lub przegrywamy pewną kwotę. Opisuje to zmienna losowa X , w tabeli mamy jej rozkład.

$$X(\omega) = \begin{cases} -40 & \text{jeśli wypadnie } 1, 2, 3 \\ 30 & \text{jeśli wypadnie } 4, 5 \\ 120 & \text{jeśli wypadnie } 6 \end{cases}$$

x_i	-40	30	120
p_i	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$

Dla każdego rozkładu definiujemy parametry, które niosą o nim pewne informacje – są to np. wartość oczekiwana, wariancja, odchylenie standardowe czy skośność.

► Wartość oczekiwana

$$m = E(X) = x_1 p_1 + x_2 p_2 + \dots + x_n p_n + \dots = \sum_n x_n p_n$$

► Wariancja

$$\begin{aligned} \text{Var}(X) &= E(X - m)^2 = (x_1 - m)^2 p_1 + (x_2 - m)^2 p_2 + \dots + (x_n - m)^2 p_n \dots = \\ &= \sum_n (x_n - m)^2 p_n \end{aligned}$$

► Odchylenie standardowe: $\sigma = \sqrt{\text{Var}(X)}$

Definiujemy też parametry

► k -ty moment zwykły: $E(X^k) = \sum_n x_n^k p_n$

► k -ty moment centralny: $E(X - m)^k = \sum_n (x_n - m)^k p_n$.

Wariancja jest drugim momentem centralnym.

Parametry rozkładu – przykład

Przykład cd.

Wróćmy do rozkładu zmiennej losowej X opisującej wygraną

x_i	-40	30	120
p_i	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$

Wartość oczekiwana

$$E(X) = -40 \cdot \frac{1}{2} + 30 \cdot \frac{1}{3} + 120 \cdot \frac{1}{6} = 10$$

Wariancja

$$\text{Var}(X) = (-40 - 10)^2 \cdot \frac{1}{2} + (30 - 10)^2 \cdot \frac{1}{3} + (120 - 10)^2 \cdot \frac{1}{6} = 3400$$

Odchylenie standardowe

$$\sigma = \sqrt{3400} \approx 58$$

Własności wartości oczekiwanej i wariancji

Dla dowolnych liczb $a, b \in \mathbb{R}$ i dowolnych zmiennych losowych X i Y , zachodzi

- ▶ $E(aX + b) = aEX + b$, $E(X + Y) = EX + EY$
- ▶ $\text{Var}(aX + b) = a^2\text{Var}(X)$, $\text{Var}(X) = E(X^2) - E^2(X)$.

Przykład cd.

Dla zmiennej losowej X opisującej wygraną

x_i	-40	30	120
p_i	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$

mamy

$$E(X^2) = (-40)^2 \cdot \frac{1}{2} + 30^2 \cdot \frac{1}{3} + 120^2 \cdot \frac{1}{6} = 3500.$$

Skąd wariancja jako różnica drugiego momentu i kwadratu wartości oczekiwanej wynosi

$$\text{Var}(X) = E(X^2) - E^2X = 3500 - 10^2 = 3400.$$

Ważne rozkłady dyskretne

- ▶ **rozkład jednopunktowy** – zmienna losowa X przyjmuje jedną wartość a z prawdopodobieństwem $P(X = a) = 1$.

Momenty: $EX = a$ i $\text{Var}X = 0$

Ważne rozkłady dyskretne

- ▶ **rozkład jednopunktowy** – zmienna losowa X przyjmuje jedną wartość a z prawdopodobieństwem $P(X = a) = 1$.

Momenty: $EX = a$ i $\text{Var}X = 0$

- ▶ **rozkład dwupunktowy** – zmienna losowa X przyjmuje dwie różne wartości a i b , z prawdopodobieństwami

$$P(X = a) = p \quad i \quad P(X = b) = q,$$

gdzie $p, q > 0$ i $p + q = 1$. Szczególnym przypadkiem tego rozkładu jest rozkład **zero-jedynkowy**, gdzie $a = 1$ i $b = 0$.

Momenty: $EX = pa + qb$ i $\text{Var}X = pq(a - b)^2$

Ważne rozkłady dyskretne

- ▶ **rozkład jednopunktowy** – zmienna losowa X przyjmuje jedną wartość a z prawdopodobieństwem $P(X = a) = 1$.

Momenty: $EX = a$ i $\text{Var}X = 0$

- ▶ **rozkład dwupunktowy** – zmienna losowa X przyjmuje dwie różne wartości a i b , z prawdopodobieństwami

$$P(X = a) = p \quad \text{ i } \quad P(X = b) = q,$$

gdzie $p, q > 0$ i $p + q = 1$. Szczególnym przypadkiem tego rozkładu jest rozkład **zero-jedynkowy**, gdzie $a = 1$ i $b = 0$.

Momenty: $EX = pa + qb$ i $\text{Var}X = pq(a - b)^2$

- ▶ **rozkład Bernoulliego (dwumianowy) $B(n, p)$** – zmienna losowa X przyjmuje wartości $0, 1, 2, \dots, n$ z prawdopodobieństwem

$$P(X = k) = \binom{n}{k} p^k q^{n-k},$$

gdzie $p \in (0, 1)$ i $p + q = 1$. Jest to rozkład liczby sukcesów w n doświadczeniach Bernoulli'ego, gdzie szansa sukcesu w jednym doświadczeniu wynosi p .

Momenty: $EX = np$ i $\text{Var}X = npq$

Ważne rozkłady dyskretne

- **rozkład Poissona** $P(\lambda)$ – zmienna losowa X przyjmuje wartości $0, 1, 2, 3, \dots$, z prawdopodobieństwem

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda},$$

gdzie $\lambda > 0$ jest parametrem.

Momenty: $EX = \lambda$ i $\text{Var}X = \lambda$

Uwaga. Czasem rozkład Poissona nazywa się „rozkładem zdarzeń rzadkich” albo „prawem małych liczb”. Mogą to być pożary, wypadki czy też główne nagrody w grach losowych. Występowanie rozkładu Poissona badał Bortkiewicz w pracy z roku 1895. Była tam mowa o zgonach na skutek kopnięcia przez konia w armii pruskiej. (*Wstęp do teorii prawdopodobieństwa* - Jacek Jakubowski, Rafał Sztencel.)

Zobacz Przykład 1 i Przykład 2 w skrypcie 01RozkładyDyskretne-wyklad.R

Rozkład Bernoullie'go a rozkład Poissona

Rozkład Bernoullie'go przy spełnieniu pewnych warunków można aproksymować rozkładem Poissona.

Twierdzenie Poissona

Niech (X_n) będzie ciągiem zmiennych losowych o rozkładzie dwumianowym $B(n, p_n)$. Jeżeli

$$\lim_{n \rightarrow \infty} n \cdot p_n = \lambda > 0,$$

to

$$\lim_{n \rightarrow \infty} P(X_n = k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

dla $k = 0, 1, 2, \dots$.

Rozkład Bernoullie'go a rozkład Poissona

Przykład. Urna zawiera 1 kulę białą i 49 kul czarnych. Losujemy z niej 50 razy po jednej kuli zwracając zawsze wylosowaną kulę z powrotem do urny. Jakie jest prawdopodobieństwo wylosowania co najmniej dwa razy kuli białej?

Mamy tutaj do czynienia ze schematem Bernoullie'go o prawdopodobieństwie sukcesu (wylosowania kuli białej) w jednym doświadczeniu $p = \frac{1}{50}$. Niech X będzie liczbą sukcesów w pięćdziesięciu doświadczeniach. Prawdopodobieństwo, że będziemy mieli ich dokładnie k , wynosi

$$P(X = k) = \binom{50}{k} \left(\frac{1}{50}\right)^k \left(\frac{49}{50}\right)^{50-k}.$$

Szukane prawdopodobieństwo wynosi zatem

$$\begin{aligned} P(X \geq 2) &= 1 - P(X < 2) = 1 - P(X = 0) - P(X = 1) \\ &= 1 - \binom{50}{0} \left(\frac{1}{50}\right)^0 \left(\frac{49}{50}\right)^{50} - \binom{50}{1} \left(\frac{1}{50}\right) \left(\frac{49}{50}\right)^{49} = 0,2642286. \end{aligned}$$

Rozkład Bernoullie'go a rozkład Poissona

Przykład. Urna zawiera 1 kulę białą i 49 kul czarnych. Losujemy z niej 50 razy po jednej kuli zwracając zawsze wylosowaną kulę z powrotem do urny. Jakie jest prawdopodobieństwo wylosowania co najmniej dwa razy kuli białej?

Mamy tutaj do czynienia ze schematem Bernoullie'go o prawdopodobieństwie sukcesu (wylosowania kuli białej) w jednym doświadczeniu $p = \frac{1}{50}$. Niech X będzie liczbą sukcesów w pięćdziesięciu doświadczeniach. Prawdopodobieństwo, że będziemy mieli ich dokładnie k , wynosi

$$P(X = k) = \binom{50}{k} \left(\frac{1}{50}\right)^k \left(\frac{49}{50}\right)^{50-k}.$$

Szukane prawdopodobieństwo wynosi zatem

$$\begin{aligned} P(X \geq 2) &= 1 - P(X < 2) = 1 - P(X = 0) - P(X = 1) \\ &= 1 - \binom{50}{0} \left(\frac{1}{50}\right)^0 \left(\frac{49}{50}\right)^{50} - \binom{50}{1} \left(\frac{1}{50}\right) \left(\frac{49}{50}\right)^{49} = 0,2642286. \end{aligned}$$

Korzystając z twierdzenia Poissona mamy ($\lambda = np = 1$)

$$\begin{aligned} P(X \geq 2) &= 1 - P(X = 0) - P(X = 1) \\ &\approx 1 - e^{-1} \frac{1^0}{0!} - e^{-1} \frac{1^1}{1!} = 0,2642411. \end{aligned}$$

Rozkład Bernoullie'go a rozkład Poissona

Przykład. Prawdopodobieństwo p trafienia „szóstki” w Toto-Lotku jest równe $1/\binom{49}{6} = 1/13983816 \approx 7 \cdot 10^{-8}$. Ilu „szóstek” można się spodziewać w każdym tygodniu, jeśli grający wypełniają kupony całkowicie losowo i niezależnie od siebie, a kuponów jest $n = 10^7$?

Zgodnie z twierdzeniem Poissona liczba „szóstek” ma rozkład zbliżony do rozkładu Poissona z parametrem $\lambda = np = 0,7151$. Szanse pojawienia się 0, 1 i 2 „szóstek” wynoszą zatem

$$P(X = 0) \approx \frac{\lambda^0}{0!} \cdot e^{-\lambda} = 0,4891, \quad P(X = 1) \approx \frac{\lambda^1}{1!} \cdot e^{-\lambda} = 0,3498,$$

$$P(X = 2) \approx \frac{\lambda^2}{2!} \cdot e^{-\lambda} = 0,1251.$$

Zobacz Przykład 3 w skrypcie 01RozkładyDyskretne.R

Skośność i kurtoza

W analizie rozkładów korzysta się też ze skośności i kurtozy. Po transformacji liniowej zmiennej X

$$Y = \frac{X - m}{\sigma},$$

gdzie $m = EX$, $\sigma^2 = \text{Var}(X)$, otrzymujemy zmienną standaryzowaną czyli taką, dla której

$$EY = 0, \quad \text{Var}(Y) = 1.$$

Skośność i kurtoza

W analizie rozkładów korzysta się też ze skośności i kurtozy. Po transformacji liniowej zmiennej X

$$Y = \frac{X - m}{\sigma},$$

gdzie $m = EX$, $\sigma^2 = \text{Var}(X)$, otrzymujemy zmienną standaryzowaną czyli taką, dla której

$$EY = 0, \quad \text{Var}(Y) = 1.$$

Skośność i **kurtozę** zmiennej X definiujemy jako odpowiednio trzeci i czwarty moment tej zmiennej po standaryzacji

$$sk = EY^3 = \frac{E(X - m)^3}{\sigma^3}, \quad \kappa = EY^4 = \frac{E(X - m)^4}{\sigma^4}.$$

Jeśli skośność jest dodatnia to mówimy, że rozkład jest prawostronnie skośny, jeśli ujemna – lewostronnie skośny. Gdy równa zero rozkład jest symetryczny.

(Ładne wykresy, zobacz: <https://en.wikipedia.org/wiki/Skewness>)

Kurtoza informuje o spłaszczeniu rozkładu. Więcej na ten temat przy rozkładach ciągłych.

Zobacz Przykład 4 w skrypcie 01RozkładyDyskretne.R

Rozkład zmiennej losowej opisujemy też dystrybuantą.

Definicja

Dystrybuantą zmiennej losowej X nazywamy funkcję $F : \mathbb{R} \rightarrow \mathbb{R}$, która każdemu elementowi $x \in \mathbb{R}$ przyporządkowuje prawdopodobieństwo

$$F(x) = P(X \leq x).$$

Przykład

Dystrybuanta zmiennej losowej X opisującej wygraną dana jest wzorem

$$F(x) = \begin{cases} 0 & \text{dla } x \leq -40 \\ \frac{1}{2} & \text{dla } x \in (-40, 30) \\ \frac{5}{6} & \text{dla } x \in (30, 120) \\ 1 & \text{dla } x > 120. \end{cases}$$

x_i	-40	30	120
p_i	$\frac{1}{2}$	$\frac{1}{3}$	$\frac{1}{6}$

Przykład

Dystrybuanta zmiennej losowej X dana jest wzorem

$$F(x) = \begin{cases} 0 & \text{dla } x \leq 1 \\ \frac{1}{8} & \text{dla } x \in (1, 3) \\ \frac{3}{8} & \text{dla } x \in (3, 5) \\ \frac{7}{8} & \text{dla } x \in (5, 7) \\ 1 & \text{dla } x > 7. \end{cases}$$

Podaj, jakie wartości przyjmuje zmienna losowa X z niezerowym prawdopodobieństwem.

Wartości z odpowiednimi prawdopodobieństwami podane są w tabeli.

x_i	1	3	5	7
p_i	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{8}$

Twierdzenie

Dystrybuanta spełnia następujące własności

- ▶ $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1,$
- ▶ *jest funkcją niemalejącą,*
- ▶ *jest funkcją lewostronnie ciągłą.*

Uwaga. W niektórych zastosowaniach wygodniej jest zdefiniować dystrybuantę jako funkcję $F(x) = P(X \leq x)$.