

# Wektory losowe

Joanna Czarnowska<sup>1</sup>

<sup>1</sup>Uniwersytet Gdański  
Instytut Informatyki

# Rozkład wektora losowego dyskretnego

Niech  $X$  i  $Y$  będą zmiennymi losowymi. Parę  $(X, Y)$  nazywamy **wektorem losowym** dwuwymiarowym.

Mówimy, że wektor jest **typu dyskretnego**, jeśli zmienne losowe  $X$  i  $Y$  są typu dyskretnego.

## Definicja

Niech  $X$  będzie zmienną losową przyjmującą wartości  $\{x_1, x_2, x_3, \dots\}$ , a  $Y$  zmienną losową o wartościach  $\{y_1, y_2, y_3, \dots\}$ . Przez  $p_{kl}$  oznaczmy prawdopodobieństwo

$$p_{kl} = P(X = x_k, Y = y_l), \quad k, l = 1, 2, \dots$$

Zbiór  $\{(x_k, y_l), p_{kl}\}_{k,l \geq 1}$  nazywamy rozkładem wektora  $(X, Y)$ .

# Rozkład wektora losowego dyskretnego – przykład

Rozkład wektora dwuwymiarowego dyskretnego można przedstawić w tabeli.

**Przykład 1.** Rozkład wektora  $(X, Y)$ .

$y \backslash x$	-1	0	1	$P(Y = y)$
-1	0,2	0	0,2	
0	0	0,2	0	
1	0,2	0	0,2	
$P(X = x)$				

Z tabeli odczytujemy na przykład, że prawdopodobieństwo zdarzenia w którym jednocześnie  $X$  i  $Y$  przyjmuje wartość  $-1$  wynosi:  $P(X = -1, Y = -1) = 0,2$ .

Mając dany rozkład wektora  $(X, Y)$ , możemy wyznaczyć rozkłady zmiennych losowych  $X$  i  $Y$ , czyli **rozkłady brzegowe**

$$P(X=x_i) = P(X=x_i, Y=y_1) + P(X=x_i, Y=y_2) + \dots = \sum_{j=1}^{\infty} P(X=x_i, Y=y_j),$$

$$P(Y=y_j) = P(X=x_1, Y=y_j) + P(X=x_2, Y=y_j) + \dots = \sum_{i=1}^{\infty} P(X=x_i, Y=y_j).$$

# Rozkłady brzegowe – przykład

Rozkład łączny wektora  $(X, Y)$  i rozkłady brzegowe (na brzegach tabeli)

$y \backslash x$	-1	0	1	$P(Y = y)$
-1	0,2	0	0,2	0,4
0	0	0,2	0	0,2
1	0,2	0	0,2	0,4
$P(X = x)$	0,4	0,2	0,4	

# Rozkłady brzegowe, a rozkład wektora

Powstaje pytanie, czy znając rozkłady brzegowe, czyli rozkłady zmiennych  $X$  i  $Y$  można wyznaczyć rozkład wektora  $(X, Y)$ ?

Odpowiedź brzmi, że w ogólnym przypadku – nie. Możemy to zrobić, gdy zmienne  $X$  i  $Y$  są niezależne.

# Niezależność zmiennych losowych

## Definicja

Dyskretne zmienne losowe  $X$  i  $Y$  nazywamy **niezależnymi**, jeśli

$$P(X = x, Y = y) = P(X = x) \cdot P(Y = y) \quad (1)$$

dla wszystkich  $x, y \in \mathbb{R}$ . Zmienne losowe które nie są niezależne, nazywamy **zależnymi**.

# Niezależność zmiennych losowych – przykład

**Przykład 1 c.d.** Rozkład wektora  $(X, Y)$ .

$y \backslash x$	-1	0	1	$P(Y = y)$
-1	0,2	0	0,2	0,4
0	0	0,2	0	0,2
1	0,2	0	0,2	0,4
$P(X=x)$	0,4	0,2	0,4	

Zmienne losowe  $X$  i  $Y$  są zależne

$$P(X = -1, Y = -1) = 0,2, \quad P(X = -1) \cdot P(Y = -1) = 0,4 \cdot 0,4 = 0,8,$$

a zatem  $P(X = -1, Y = -1) \neq P(X = -1) \cdot P(Y = -1)$ .



# Niezależność zmiennych losowych – przykład

**Przykład 2.** W tabeli podany jest rozkład wektora  $(X, Y)$ . Zmienne losowe  $X$  i  $Y$  są niezależne.

$y \backslash x$	1	0	$P(Y = y)$
1	$\frac{1}{12}$	$\frac{1}{6}$	$\frac{1}{4}$
2	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{3}{4}$
$P(X=x)$	$\frac{1}{3}$	$\frac{2}{3}$	

# Wartość oczekiwana iloczynu zmiennych losowych

Wartość oczekiwaną iloczynu dyskretnych zmiennych losowych  $X \in \{x_1, x_2, \dots\}$  i  $Y \in \{y_1, y_2, \dots\}$  możemy obliczyć korzystając z zależności

$$E(XY) = \sum_{k,l \geq 1} x_k y_l \cdot P(X = x_k, Y = y_l).$$

## Twierdzenie

Jeżeli zmienne losowe  $X$  i  $Y$  są niezależne, to

$$E(XY) = EX \cdot EY.$$

# Niezależność zmiennych losowych – przykład

**Przykład 2. c.d.** Zmienne losowe  $X$  i  $Y$  są niezależne.

$y \backslash x$	1	0	$P(Y = y)$
1	$\frac{1}{12}$	$\frac{1}{6}$	$\frac{1}{4}$
2	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{3}{4}$
$P(X=x)$	$\frac{1}{3}$	$\frac{2}{3}$	

$$EX = 1/3,$$

$$EY = 1/4 + 6/4 = 7/4$$

$$E(XY) = 1/12 + 2/4 = 7/12 = EXEY$$

# Kowariancja. Współczynnik korelacji Pearsona

Do opisu zależności między zmiennymi losowymi, wykorzystuje się kowariancję oraz współczynnik korelacji Pearsona.

Oznaczmy  $EX = \mu_1$  i  $EY = \mu_2$ .

**Kowariancję** zmiennych losowych  $X$  i  $Y$  nazywamy liczbę

$$\text{cov}(X, Y) = E(X - \mu_1)(Y - \mu_2).$$

Siłę zależności mierzy **współczynnik korelacji Pearsona**, definiowany jako wartość oczekiwana iloczynu zmiennych losowych standaryzowanych

$$\rho(X, Y) = E\left(\frac{X - \mu_1}{\sigma_1} \frac{Y - \mu_2}{\sigma_2}\right) = \frac{\text{cov}(X, Y)}{\sigma_1 \sigma_2},$$

gdzie  $\sigma_1^2 = \text{Var}X$  i  $\sigma_2^2 = \text{Var}Y$ .

## Fakt

Dla dowolnych zmiennych losowych  $X$  i  $Y$  mamy

- a)  $\text{cov}(X, Y) = E(XY) - EXEY$ ,
- b)  $\text{cov}(X, X) = \text{Var}(X)$ ,  $\text{cov}(X, Y) = \text{cov}(Y, X)$ ,
- c) jeśli  $X$  i  $Y$  są zmiennymi niezależnymi, to  $\text{cov}(X, Y) = 0$  oraz  $\rho(X, Y) = 0$ .

*Dowód a)* Korzystając z własności wartości oczekiwanej, mamy

$$\begin{aligned}\text{cov}(X, Y) &= E(X - \mu_1)(Y - \mu_2) \\&= E(XY - \mu_2X - \mu_1Y + \mu_1\mu_2) \\&= E(XY) - E(\mu_2X) - E(\mu_1Y) + E(\mu_1\mu_2) \\&= E(XY) - \mu_2EX - \mu_1EY + E(\mu_1\mu_2) \\&= E(XY) - \mu_2\mu_1 - \mu_1\mu_2 + \mu_1\mu_2 \\&= E(XY) - \mu_1\mu_2.\end{aligned}$$

# Współczynnik korelacji Pearsona

Współczynnik  $\rho$  przyjmuje wartości z przedziału  $\langle -1, 1 \rangle$ .

- ▶ Jeżeli  $\rho > 0$  mówimy, że zmienne są skorelowane dodatnio,
- ▶ jeżeli  $\rho < 0$  – skorelowane ujemnie,
- ▶ w przypadku, gdy  $\rho = 0$  mówimy, że zmienne są nieskorelowane.

Zachodzą zależności

- ▶  $\rho = 1 \iff P(Y=aX+b) = 1$ , dla pewnych stałych  $a > 0, b \in \mathbb{R}$ ,
- ▶  $\rho = -1 \iff P(Y=aX+b) = 1$ , dla pewnych stałych  $a < 0, b \in \mathbb{R}$ .

Można też łatwo wykazać, że wariancja sumy zmiennych losowych jest równa sumie wariancji oraz podwojonej wartości kowariancji

$$\begin{aligned} \text{Var}(X + Y) &= \text{Var}X + \text{Var}Y + 2\text{cov}(X, Y) \\ &= \sigma_1^2 + \sigma_2^2 + 2\rho\sigma_1\sigma_2. \end{aligned}$$

# Współczynnik korelacji Pearsona – przykład

**Przykład 1. c.d.** Zmienne losowe  $X$  i  $Y$  mają taki sam rozkład. Mamy

- ▶  $EX = EY = 0$ ,  $E(X^2) = E(Y^2) = 0,8$ ,  $E(XY) = 0$ ,
- ▶  $VarX = VarY = 0,8$ .

Stąd  $\rho = 0$ . Zauważmy, że zmienne  $X$  i  $Y$  są zależne.

$y \backslash x$	-1	0	1	$P(Y = y)$
-1	0,2	0	0,2	0,4
0	0	0,2	0	0,2
1	0,2	0	0,2	0,4
$P(X=x)$	0,4	0,2	0,4	

**Uwaga.**

- ▶  $X, Y$  niezależne  $\Rightarrow X, Y$  nieskorelowane.
- ▶  $X, Y$  nieskorelowane  $\nRightarrow X, Y$  niezależne.

# Współczynnik korelacji Pearsona – przykład

**Przykład 3.** W tabeli podany jest rozkład łączny wektora  $(X, Y)$  oraz rozkłady zmiennych  $X$  i  $Y$  (rozkłady brzegowe).

$y \backslash x$	-1	0	1	$P(Y = y)$
-1	0,2	0	0,2	0,4
0	0	0,4	0	0,4
1	0	0	0,2	0,2
$P(X=x)$	0,2	0,4	0,4	

Współczynnik korelacji  $\rho \approx 0,43$ .



## Definicja

**Dystrybuantą** wektora  $(X, Y)$  nazywamy funkcję  $F : \mathbb{R}^2 \rightarrow \mathbb{R}$  taką, że

$$F(x, y) = P(X \leq x, Y \leq y),$$

dla każdego  $x, y \in \mathbb{R}$ .

# Rozkłady dwuwymiarowe ciągłe


Mówimy, że wektor  $(X, Y)$  o dystrybucanie  $F$  jest **typu ciągłego**, jeśli istnieje funkcja nieujemna  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  taka, że

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv,$$

dla każdego  $x, y \in \mathbb{R}$ .

Funkcję  $f$  nazywamy **gęstością** rozkładu wektora  $(X, Y)$ . Mamy

$$f(x, y) = \frac{\partial^2 F}{\partial x \partial y}(x, y).$$



# Rozkłady dwuwymiarowe ciągłe

## Fakt

Funkcja  $f$  jest gęstością rozkładu pewnego wektora  $(X, Y)$  wtedy i tylko wtedy, gdy

- ▶  $f(x, y) \geq 0$ , dla każdego  $(x, y) \in \mathbb{R}$ ,
- ▶  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$ .

Prawdopodobieństwo, że wektor  $(X, Y)$  przyjmuje wartości ze zbioru  $D \subset \mathbb{R}^2$  obliczamy, korzystając z zależności

$$P((X, Y) \in D) = \iint_D f(x, y) dx dy.$$

**Przykład 4.** Wektor  $(X, Y)$  ma rozkład o gęstości

$$f(x, y) = \begin{cases} e^{-x-y}, & \text{dla } x > 0 \text{ i } y > 0, \\ 0, & \text{dla pozostałych wartości.} \end{cases}$$

$$\begin{aligned} P((X, Y) \in (1, 2) \times (1, 3)) &= \int_1^2 \int_1^3 e^{-x-y} dx dy \\ &= (e^{-1} - e^{-2})(e^{-1} - e^{-3}) \approx 0,07. \end{aligned}$$

## Fakt

Jeśli wektor  $(X, Y)$  jest typu ciągłego o gęstości  $f$ , to zmienne losowe  $X$  i  $Y$  też są typu ciągłego i ich gęstości możemy wyznaczyć z zależności

$$f_1(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad f_2(y) = \int_{-\infty}^{\infty} f(x, y) dx,$$

gdzie  $f_1$  jest gęstością zmiennej losowej  $X$ , a  $f_2$  zmiennej losowej  $Y$ .

## Przykład 4 c.d.

$$f_1(x) = \int_0^{\infty} e^{-x-y} dy = e^{-x}, \text{ dla } x > 0$$

$$f_2(y) = \int_0^{\infty} e^{-x-y} dx = e^{-y}, \text{ dla } y > 0$$

# Niezależność zmiennych losowych

## Definicja

Zmienne losowe  $X$  i  $Y$  nazywamy **niezależnymi**, jeśli

$$F(x, y) = F_1(x) \cdot F_2(y),$$

gdzie  $F_1$ ,  $F_2$  i  $F$  są odpowiednio dystrybuantami zmiennych  $X$  i  $Y$  oraz wektora  $(X, Y)$ .


Dla rozkładów ciągłych, powyższa definicja jest równoważna warunkowi

$$f(x, y) = f_1(x) \cdot f_2(y), \quad (2)$$

gdzie  $f_1$ ,  $f_2$  i  $f$  są gęstościami zmiennych  $X$  i  $Y$  oraz wektora  $(X, Y)$ , natomiast dla rozkładów dyskretnych, warunkowi (1).

Zmienne losowe z Przykładu 4 spełniają warunek (2), zatem są niezależne.


# Rozkład normalny standardowy



Gęstość wektora  $Z = (Z_1, Z_2)^T$ , gdzie zmienne losowe  $Z_1, Z_2$  są niezależne o jednakowym rozkładzie normalnym standardowym  $N(0, 1)$ , jest zgodnie z (2) iloczynem gęstości rozkładów brzegowych

$$f(x_1, x_2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x_1^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x_2^2}{2}} = \frac{1}{2\pi} e^{-\frac{x_1^2 + x_2^2}{2}}. \quad (3)$$

Rozkład o gęstości  $f$ , nazywamy rozkładem **normalnym standardowym**, dwuwymiarowym.



# Rozkład normalny standardowy dwuwymiarowy

Opisując wektor normalny standardowy  $Z = (Z_1, Z_2)$ , podajemy wektor wartości oczekiwanych oraz macierz kowariancji, która niesie informacje o zależnościach między zmiennymi.

**Wektor wartości oczekiwanych:**  $E(Z) = (EZ_1, EZ_2) = (0, 0)$ .

**Macierz kowariancji:**

$$\begin{aligned}\Sigma &= \begin{bmatrix} \text{cov}(Z_1, Z_1) & \text{cov}(Z_1, Z_2) \\ \text{cov}(Z_2, Z_1) & \text{cov}(Z_2, Z_2) \end{bmatrix} \\ &= \begin{bmatrix} \text{Var}(Z_1) & \text{cov}(Z_1, Z_2) \\ \text{cov}(Z_2, Z_1) & \text{Var}(Z_2) \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I_2\end{aligned}$$

► Zauważ, że zmienne  $Z_1$  i  $Z_2$  są niezależne, zatem  $\text{cov}(Z_1, Z_2) = 0$ .

Piszemy  $Z \sim N(0, I_2)$ , gdzie  $I_2$  oznacza macierz jednostkową w  $\mathbb{R}^2$ .



# Rozkład normalny dwuwymiarowy

Niech  $Z = (Z_1, Z_2) \sim N_2(0, I_2)$ .

Mówimy, że wektor  $X = (X_1, X_2)$  ma **rozkład normalny dwuwymiarowy** (rozkład Gaussowski), jeżeli jest transformacją liniową

$$\begin{cases} X_1 = \mu_1 + a_{11}Z_1 + a_{12}Z_2 \\ X_2 = \mu_2 + a_{21}Z_1 + a_{22}Z_2 \end{cases} \quad (4)$$



lub w postaci macierzowej

$$X = \mu + AZ,$$

gdzie  $\mu = (\mu_1, \mu_2) \in \mathbb{R}^2$  jest wektorem stałych oraz

$$A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$$

gdzie  $A$  jest macierzą nieosobliwą.



# Rozkład normalny dwuwymiarowy

Jeśli wektor  $X$  ma rozkład normalny, to wartość oczekiwana  $EX$  i macierz kowariancji  $\Sigma$  jednoznacznie wyznaczają rozkład tego wektora.

**Wartość oczekiwana:**  $\mu = EX = (EX_1, EX_2) = (\mu_1, \mu_2)$

**Macierz kowariancji:**

$$\Sigma = \begin{bmatrix} \text{cov}(X_1, X_1) & \text{cov}(X_1, X_2) \\ \text{cov}(X_2, X_1) & \text{cov}(X_2, X_2) \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix},$$

gdzie  $\sigma_1, \sigma_2$  są odchyleniami standardowymi, a  $\rho$  jest współczynnikiem korelacji.

Można wykazać też, że  $\Sigma = AA^T$ .

Piszemy  $(X_1, X_2) \sim N(\mu, \Sigma)$  lub  $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$ .

# Gęstość rozkładu normalnego dwuwymiarowego

Mając gęstość rozkładu dwuwymiarowego standardowego (3) oraz definicję (4) można wykazać, że **gęstość rozkładu normalnego dwuwymiarowego** dana jest wzorem

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]\right). \quad (5)$$

Na przykład gęstość rozkładu  $N(0, 0, 1, 1, 0.9)$  dana jest wzorem

$$f(x_1, x_2) = \frac{5\sqrt{19}}{19\pi} \exp\left(-\frac{50}{19}\left(x_1^2 - \frac{9}{5}x_1x_2 + x_2^2\right)\right).$$


Wykres gęstości na kolejnym slajdzie.

# Rozkład normalny dwuwymiarowy – wybrane gęstości

Gęstości rozkładów  $N(0, 0, 1, 1, -0,7, )$ ,  $N(0, 0, 1, 1, 0)$ ,  $N(0, 0, 1, 1, 0,9)$ .


Dwuwymiarowy Rozkład Normalny

$\rho = -0,7$




Dwuwymiarowy Rozkład Normalny

$\rho = 0$






Dwuwymiarowy Rozkład Normalny

$\rho = 0,9$



Próby wygenerowane z powyższych rozkładów.



## Fakt

Niech  $(X_1, X_2) \sim N(\mu_1, \mu_2, \sigma_1, \sigma_2, \rho)$ . Wtedy

- ▶ rozkłady brzegowe są też rozkładami normalnymi  
 $X_1 \sim N(\mu_1, \sigma_1), \quad X_2 \sim N(\mu_2, \sigma_2),$
- ▶ zmienne  $X_1$  i  $X_2$  są niezależne wtedy i tylko wtedy, gdy są nieskorelowane.

Dla  $\rho = 0$  z (5) mamy

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2} \left[ \frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right]\right) \\ &= \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2} \frac{(x_1 - \mu_1)^2}{\sigma_1^2}\right) \cdot \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{1}{2} \frac{(x_2 - \mu_2)^2}{\sigma_2^2}\right) = f_1(x_1) \cdot f_2(x_2). \end{aligned}$$

# Rozkład normalny d-wymiarowy

Analogicznie do rozkładu dwuwymiarowego (4), możemy zdefiniować rozkład normalny  $d$ -wymiarowy o wartości oczekiwanej  $EX = (EX_1, \dots, EX_d)$  i macierzy kowariancji

$$\Sigma = \begin{bmatrix} \text{cov}(X_1, X_1) & \text{cov}(X_1, X_2) & \cdots & \text{cov}(X_1, X_d) \\ \text{cov}(X_2, X_1) & \text{cov}(X_2, X_2) & \cdots & \text{cov}(X_2, X_d) \\ \vdots & \vdots & \ddots & \vdots \\ \text{cov}(X_d, X_1) & \text{cov}(X_d, X_2) & \cdots & \text{cov}(X_d, X_d) \end{bmatrix}$$

które też jednoznacznie wyznaczają ten rozkład.

► Gęstość rozkładu normalnego  $d$ -wymiarowego

$$f(x_1, \dots, x_d) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \exp \left[ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right], \quad (6)$$

gdzie  $x = (x_1, \dots, x_d)^T$ ,  $\mu = (EX_1, \dots, EX_d)^T$ , a  $|\Sigma|$  jest wyznacznikiem macierzy kowariancji.

# Rozkład normalny $d$ -wymiarowy

- ▶ Jeśli wektor  $(X_1, \dots, X_d)$  ma rozkład normalny  $d$ -wymiarowy (6), to rozkłady brzegowe też są rozkładami normalnymi  $X_i \sim N(\mu_i, \sigma_i^2)$ .
- ▶ Wektor  $(X_1, X_2, \dots, X_d)$  ma rozkład normalny  $d$ -wymiarowy wtedy i tylko wtedy, gdy każda kombinacja liniowa

$$Y = a_1 X_1 + a_2 X_2 + \dots + a_d X_d,$$

ma rozkład normalny. Czyli, dla dowolnego wektora  $a \in \mathbb{R}^d$ , zmienna losowa  $Y = a^T X$  ma rozkład normalny.